

What is Escalation? Measuring Crisis Dynamics in International Relations with Human and LLM Generated Event Data

什么是升级？利用人类与LLM生成的事件数据衡量国
际关系中的危机动态

杨洁菡 何柄岐 修小苏

北京外国语大学

2026年2月

目录

1. 研究背景与核心问题
2. 理论重构
3. 数据革命
4. 分析策略
5. 总结与发现

一、研究背景与核心问题

传统困境：两种对立的理论

- 威慑模型：示强以迫使对方退缩
- 螺旋模型：示强会引发报复循环

现实挑战：

- 两种理论政策建议矛盾
- 均缺乏坚实实证基础
- 决策者困惑：下一步行动会平息事态还是火上浇油？

本研究的核心转向：

不再争论“哪派理论正确”，而是追问：

“回顾历史，什么行动真正缩短了危机，什么行动让危机拖得更久？”

一、研究背景与核心问题

“回顾历史，什么行动真正缩短了危机，什么行动让危机拖得更久？”

要科学回答这个问题，必须解决三个方法论的挑战：

1. 概念测量：

- 如何将抽象的“升级”转化为可测量的科学变量？

2. 数据挑战

- 如何构建能刻画危机动态过程的新型数据库？

3. 分析挑战

- 如何从复杂历史中量化每个行动的独立影响？

二、理论重构：跳出循环论证

传统研究的根本困境：

研究者通过观察一系列“危机性行为”（如军事动员、最后通牒）来界定一场“危机”。决策者则思考在危机中，采取某个特定行为，是会导致危机延续，还是促成危机解决？

矛盾逻辑：用行为解释危机，又用行为定义危机，无法区分行动是危机的“原因”还是“症状”？

本文的解决方案：视角转换

- 从诊断静态状态 → 观测动态过程
- 不问“这是危机吗？” → 问“这场危机还要持续多久？”

二、理论重构：核心变量定义

核心因变量：危机剩余时间

- 操作定义：在危机时间点 t ，预测到危机结束还剩多少叙事单元
- 性质：连续、直观、有明确政策含义的变量

“危机升级”的操作化新定义：

- 升级行为：使预测的“危机剩余时间”系统性延长
- 降级行为：使预测的“危机剩余时间”系统性缩短

此种定义的两大优势：

1. 避免对行为的先验理论分类
2. 兼容复杂理论（如：暴力可能因揭示信息而终结危机）

三、数据革命：现有数据的局限

两类传统数据都存在缺陷：

数据类型	代表项目	优势	对本研究的局限
冲突数据	MIDS数据集	记录结果，可靠	只有“是否打仗”，丢失全部过程细节
事件数据	CAMEO等	记录过程	海量事件流缺乏理论框架，难以分析序列逻辑

我们需要：既有过程细节，又有理论结构的新型数据

三、数据革命：ICBe-LLM数据库构建——标准化语言与编码流水线

构建新型危机数据库的三大支柱

1. 确定分析范畴：建立完整的历史危机样本框

采用“国际危机行为”（International Crisis Behavior, ICB）第12版的数据，将其记录的1918年至2019年间全球范围内的475场国际危机作为分析的完整宇宙（universe）。

2. 创立标准化分析语言：ICBe本体论（The ICBe Ontology）

数据编码的核心挑战在于“语言标准化”——如何让不同编码者（无论是人类还是机器）对同一段历史文本产生一致的解读。

ICBe本体论（The ICBe Ontology）的设计原则：

- **互斥性与完备性：**每个行为都能且只能归入一个类别，所有危机中可能会出现的关键行为都被涵盖
- **理论中立性：**避免预先赋予行为“升级”或“降级”的道德或理论标签，仅作客观描述
- **可操作性：**每个类别都有清晰的操作定义和编码示例

三、数据革命：ICBe-LLM数据库构建——标准化语言与编码流水线

构建新型危机数据库的三大支柱

3. 构建人机混合编码流水线

传统的纯人工编码面临成本高、速度慢、一致性难保证的瓶颈。本文的解决方案是建立一条人机协同的编码流水线。

第一步：高质量种子数据创建

- 由8名经过严格训练的国际关系研究生组成专家编码团队
- 每名编码员独立阅读危机叙事文本，按照ICBe本体论进行标注
- 定期进行编码一致性测试，确保团队间信度（inter-coder reliability）超过85%

第二步：训练ICBeLLM——基于大语言模型的自动化编码系统

- 模型架构：在开源LLaMA模型基础上进行微调，构建了专门的ICBeLLM系统
- 训练数据：使用上述人工编码的9,358条高质量事件作为训练集
- 任务设计：模型的任务不是简单分类，而是完成结构化信息抽取

第三步：严格的多重验证质控机制

- 双重专家验证：事件需被至少两位人类专家独立编码并达成一致
- 专家-机器验证：事件被一位人类专家和ICBeLLM系统共同确认
- 争议解决机制：出现分歧时，由第三位高级研究员仲裁
- 最终数据集中，每一个事件都有明确的“验证路径”标识

三、数据革命：定义“危机-时间步”作为分析单元

为什么需要重新定义分析单元？

传统事件数据常以“天”或“周”为时间单位，但危机动态的变化速度可能更快。外交照会、军事调动、领导人声明可能在几小时内相继发生。为捕捉这种精细的时间序列模式，需要更灵敏的时间尺度。

“危机-时间步”（Crisis-Time Step）的操作化定义：

定义：将危机叙事中每一个包含至少一个可编码ICBe事件的句子，定义为一个时间步。

示例：“A国增兵两万，B国取消会谈” = 1个时间步（含2事件）

总量：7126个“危机-时间步”构成的面板数据

数据革命的成效：


事件记录：从9358条（纯人工）→ 15487条（人机混合）

样本量提升：+65%


关键优势：零边际人力成本，实现“显微镜式”过程分析

三、数据革命：数据的内在规律验证

When Behaviors Tend to Happen within a Crisis
Mean Location within Narrative Grouped by Behavior Type



三、数据革命：数据的内在规律验证



四、分析策略：测量目的

待解决的问题：

如何从7,126个历史时间步中，量化140种行为各自对“危机剩余时间”的净影响？

现实复杂性：

非线性关系：影响不是简单加减

交互作用：“动员”后接“谈判”，效果不同

时间衰减：三天前vs三个月前的威胁，效力不同

传统线性回归难以应对 → 需要更强大的分析工具

四、分析策略：模型选择与特征工程

核心工具：LightGBM梯度提升树模型

- 非参数方法，无需预设线性关系
- 擅长捕捉非线性和特征交互
- 能灵活处理“时间距离”这一关键维度

特征工程的关键创新：

对每种行为，不记录是否发生，而是构造特征：距离该行为上次发生的时间步数

- 本期发生：0
 - 一期前发生：1
 - 从未发生：设为极大值（如100）
- 让模型自主学习每种行为的“影响衰减曲线”


四、分析策略：稳健性保障与可解释性

严格验证：嵌套交叉验证

- 将475场危机分成10份
- 每次用9份训练，用完全未参与训练的第10份测试
- 所有结论基于对“全新”危机的预测 → 确保结论可推广

从“黑箱”到可解释：SHAP值

- SHAP值：将模型预测公平分解到每个特征的贡献
- 在本研究中的意义：
 - 行为A在时间距离B上的SHAP值
 - = 该行为在该情境下对危机剩余时间的**边际影响**
 - SHAP>0：延长危机（升级）
 - SHAP<0：缩短危机（降级）



五、发现：行为效应图

热力图解读：

纵轴：对危机持续时间影响最大的行为
(按总效应排序)

- 橙色：想法/意图
- 蓝色：言论
- 红色：升级化行动
- 绿色：降级化行动
- 紫色：行动细节


横轴：该行为多久前发生 (0=刚刚发生)

颜色：

红色越深：延长危机的效应越强

紫色越深：缩短危机的效应越强

一个最直观的感受：红色和绿色行动并不会聚焦分散在纵轴两端→一个复杂的行动模式




五、发现：谁是危机延长者？

最强劲的升级行为（红色区域顶端）：

1. 形成新的军事同盟
2. 国内政治继承（政变）
3. 第三方介入
4. 发出最后通牒/中断谈判

共同特征：

1. 剧烈改变博弈结构
2. 极大增加系统不确定性
3. 即使表面是“合作”（如结盟）或“防御性”行动



五、发现：谁是危机终结者？

最有效的降级行为（紫色区域底部）：

1. 领土重大变更
2. 投降/撤军
3. 对胜败的明确认知
4. 激烈的战斗/攻击

共同特征：

1. 快速提供清晰、决定性信息
2. 大幅削减信息不对称
3. 即使代价高昂（如激烈战斗）

关键反直觉发现：

高强度的暴力（战斗）与危机缩短系统性相关

五、发现：理论启示—支持讨价还价理论

对经典理论的挑战：

- 威慑模型：未得到系统性支持（示强未缩短危机）
- 螺旋模型：解释力不足（无法解释暴力终结危机）


强有力支持“冲突的讨价还价理论”：

核心观点：危机僵持源于信息不对称

我们的实证发现：

- 危机持续时间的关键调节变量 = 信息（不确定性）动态
 - 升级的本质：采取让对手更困惑、预测更困难的行动
 - 降级的本质：采取能瞬间揭晓谜底、让结局清晰的行动
- 与行为表面“强硬/温和”无必然联系

五、发现：模型如何思考单场危机——以古巴导弹危机为例



坐标轴：

X轴：危机进程

Y轴：模型预测的“剩余时间”

关键节点：


红色标注（延长效应）：**artillery**

蓝色标注（缩短效应）：**blockade, mediation, withdraw**

意义：

模型不仅能给出平均效应，还能合理解释具体历史转折


将统计结论在著名案例中生动具象化



海湾战争：波动剧烈，多个波峰波谷，多次declaration of war恶化危机

克里米亚-顿巴斯危机：阶梯式下行，多次mediation起到缩短危机效应

五、发现：危机动态的多样性



聚类分析揭示的典型模式：

快速解决(1)：曲线骤降

拉锯反复(2)：曲线上下波动强烈，多个波峰波谷【海湾战争】

危机复发I(3)：曲线下行后快速抬升且居高不下

危机复发II(4)：类似(3)，但幅度更大

短暂升级(5)：曲线下行后又短暂抬升，随后下行【古巴导弹危机】

阶梯下行(6)：曲线台阶式下行【克里米亚危机】

意义：

- 危机的动态是多样的，但存在可分类的系统性模式
- 我们的模型成功捕捉到了这种复杂性
- 呼应理论部分关于“过程”和“偶然性”的讨论

五、发现：方法论贡献与局限

主要贡献：方法论范式推进

- LLM（数据生产） + 可解释机器学习（数据分析） 的深度融合
- 为基于历史文本的社会科学研究开辟新路径
- 提供可复现的分析框架

研究性质：

- 基于历史大数据的严谨观察性研究
- 提供强相关性证据和强大分析框架
- 为因果推断奠定基础，但非最终定论

局限与未来方向：

- 测量的是“平均历史效应”
- 未来需识别情境调节变量（政权类型、力量对比等）
- 可发展为危机管理决策支持系统

感谢聆听！

杨洁菡 何柄岐 修小苏

北京外国语大学 国际关系学院

2026年2月